

**SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY**

**SIMULAČNÝ MODEL MIKROSÚSTAVY
OBNOVITEĽNÝCH ZDROJOV ENERGIE
TÍMOVÝ PROJEKT**

Školiace pracovisko:

Ústav robotiky a kybernetiky

Školiteľ:

Ing. Slavomír Kajan, PhD. , Ing. Ladislav Körösi, PhD.

Bc. Marko Chylík

Bc. Jakub Lulák

Bc. Matej Marton

Bc. Filip Iglarčík

Bratislava 2021

Bc. Michal Hrabovský

TÍMOVÝ PROJEKT ZADANIE

Študijný program: Robotika a kybernetika
Študijný odbor: Kybernetika
Vedúci projektu: Ing. Slavomír Kajan, PhD. ,
 Ing. Ladislav Körösi, PhD.
Miesto vypracovania projektu: Ústav robotiky a kybernetiky
Riešitelia:

Názov projektu: *Simulačný model mikrosústavy obnoviteľných zdrojov energie*

Špecifikácia zadania:

Cieľom projektu je vytvoriť simulačné modely mikrosústav (mikrogridov) z vybraných typov obnoviteľných zdrojov, simulačne overiť ich fungovanie pre rôzne zapojenia a vykonať analýzy vybraných záťažových scenárov týchto mikrogridov.

Úlohy:

1. V prostredí Matlab vytvorte alebo využite existujúce modely vybraných zdrojov (veterná turbína, slnečné panely, batérie, diesel generátor, ...) a popíšte ich parametre a zapojenie do gridu.
2. Vytvorte simulačné modely mikrogridov pre vybrané zapojenia zdrojov a záťaží s možnosťou merania a analýzy veličín gridu.
3. Vykonajte ukážky simulácií rôznych záťažových scenárov pre tieto vytvorené modely mikrogridov.
4. Vytvorte neurónové modely z dát simulačného modelu mikrogridu.

Termín odovzdania projektu: 14.5.2021

V Bratislave dňa 15.2.2021

prof. Ing. Jarmila Pavlovičová PhD.
garantka študijného programu

Obsah

Obsah	3
Zoznam použitých skratiek	4
1 Simulačné modely mikrogridov	5
1.1 Prvý mikrogrid	5
1.2 Druhý mikrogrid.....	7
1.3 Tretí mikrogrid	8
2 Simulačné výsledky mikrogridov	10
2.1 Prvý mikrogrid	10
2.2 Druhý mikrogrid.....	11
2.3 Tretí mikrogrid	13
3 Neurónové modely	15
3.1 NARX.....	15
3.2 Architektúra.....	15
3.3 Trénovanie NARX	16
3.4 Hľadanie optimálnej štruktúry	18
3.5 Model prvého gridu	18
3.6 Model druhého gridu	22
3.7 Model tretieho gridu	25
4 Riadenie projektu	28
5 Záver	29
6 Zdroje	30

Zoznam použitých skratiek

Mikrogrid - mikrosústava obnoviteľných zdrojov energie

NARX – nelineárny autoregresívny neurónový model s dodatočným šumom

1 Simulačné modely mikrogridov

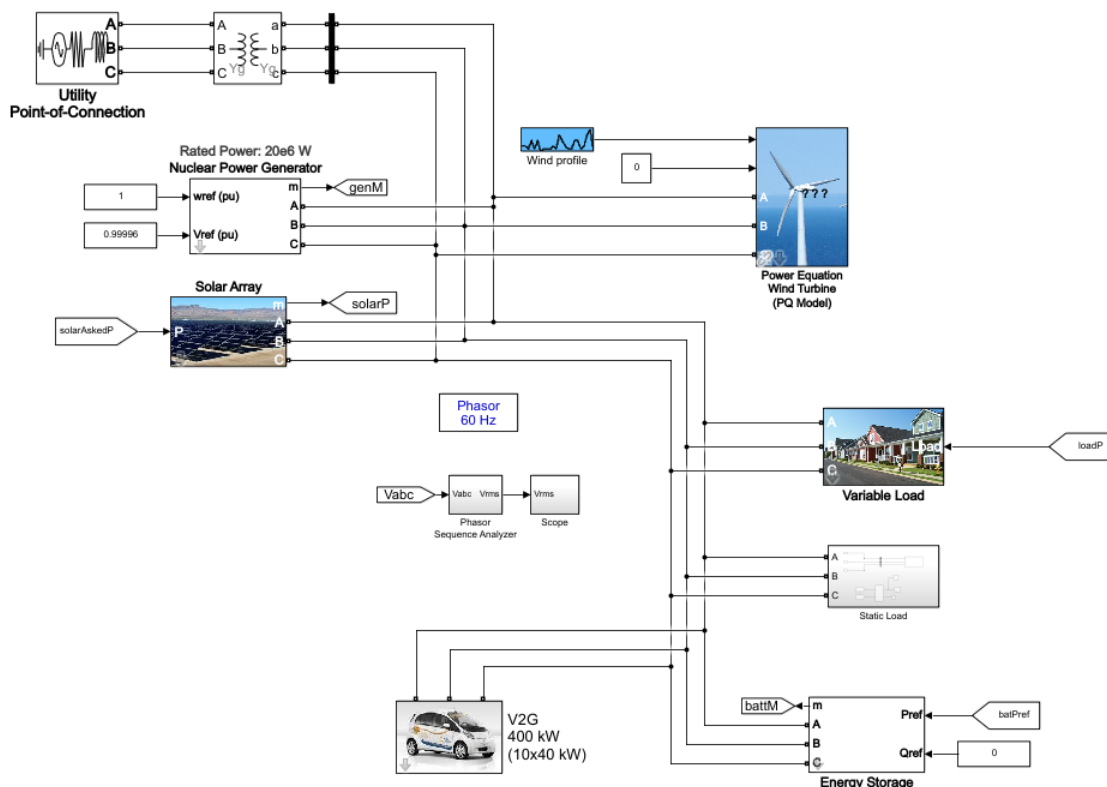
Mikrogrid je sebestačný energetický systém – má široké využitie najmä v odlhľých oblastiach, či v menších územných celkoch (napríklad novovystavané štvrte). Energeticky sebestačný v tomto slovačmysle znamená, že systém disponuje úložiskami energie, ktoré sú dopĺňané v čase prebytku energie v systéme a v prípade energetického nedostatku sú tieto zdroje využívané na vykrytie. Ďalším jasným identifikátorom je využitie obnoviteľných zdrojov – veternej, slnečnej, či vodnej energie. Sú však pripojené aj k stálym zdrojom energie, ktoré vedia v kritických situáciách udržať chod elektrickej energie. Medzi ne patrí napríklad dieselový generátor, alebo parová turbína. Mikrogridy môžu disponovať taktiež rôznymi špeciálnymi zdrojmi energie – budeme sa im venovať v konkrétnom opise jednotlivých mikrogridov. Našou úlohou bolo zostrojiť tri mikrogridy, pričom pri každom z nich budeme skúmať iné spojitosti.

1.1 Prvý mikrogrid

Prvý grid je simulačný model konkrétnej obývanej rezidenčnej oblasti v danom krátkom časovom úseku s cieľom skúmať rôzne hraničné záťažové scenáre pre el. sieť. Zelená energia dodávaná do gridu pozostáva zo solárneho panelu – v tomto gride však pre jednoduchosť slnečný zdroj dodáva stabilnú dávku energie. O zabezpečenie stálej prevádzky siete sa stará dieselový generátor. Samozrejme grid disponuje aj úložiskom energie v podobe batérii. V modeli máme niekoľko záťaží – medzi premenlivé radíme simulačný blok konkrétnej rezidenčnej zóny, ktorej spotreba je premenlivá a vytvorili sme istý záťažový profil v konkrétnom časovom výseku z dňa. V mikrogride počítame aj so stálou záťažou, avšak práve variabilné súčasti rozhodujú o správaní gridu ako celku – vieme vybudovať pomocou nich hraničné situácie, ktoré budú viesť k nestabilite.

Samozrejme, aj batérie, ako úložiská energie sú v tomto prípade variabilnou zložkou. Disponujú taktiež časovým profilom – v podstate si dopredu naplánujeme, kedy budeme batériu dobíjať a kedy zase budeme energiu z batérie spotrebúvať. Ukážky vstupných profilov budú uvedené v ďalších kapitolách.

1.2 Druhý mikrogrid



Obrázok 2: Simulačný model druhého mikrogridu

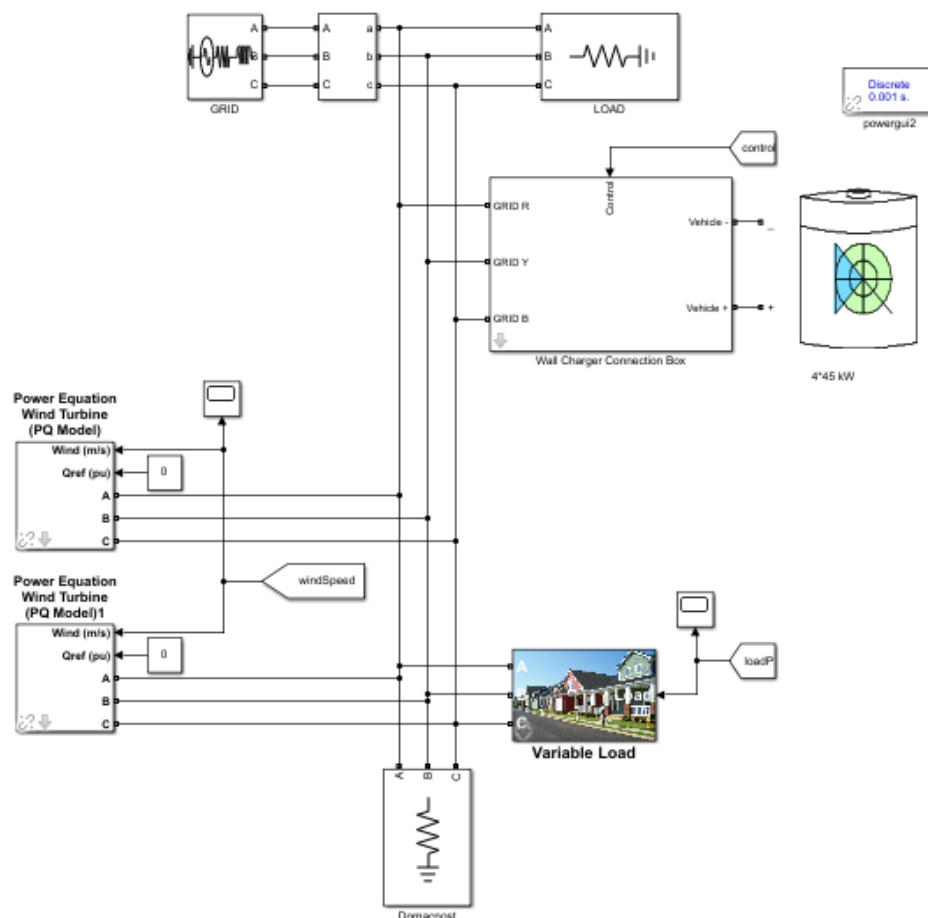
Ako základ pre tento model sme použili **V2G** model z príkladov od MATLAB. Na rozdiel od predošlého modelu disponuje tento model reálnymi dátami za 24 hodín, čo pridáva na kredibilitu modelu. V gride sa o stálu dodávku energie stará blok jadrového generátora. Premennivé a zároveň obnoviteľné zdroje energie sú solárne panely a veterná turbína. Tieto zdroje majú namerané profily žiadaných dodávok energie podľa reálnych možností za posledných 24 hodín. Napríklad je v ňom vidieť, že na slnečnú energiu sa možno spoliehať len počas dňa. Obdobný profil má aj záťažný zdroj v podobe rezidenčnej zóny – v ňom možno vidieť samozrejme vyššiu spotrebu počas dňa ako noci a tak ďalej.

Špeciálny prípad tvorí blok V2G. Je to blok integrovaného nabíjacieho systému pre elektromobily, ktorý môže do siete energiu ako dodávať, tak ju aj odoberať – záleží na preferenciách zapojených klientov. Tí si totiž môžu navoliť v akom čase potrebujú svoje auto nabité. V2G funguje tak, že pripojené autá majú personalizovaný profil, v ktorom si užívateľ navolí, o koľkej bude potrebovať svoje auto plne nabité. Ak je v sieti nedostatok energie a auto má ešte dost času aby sa nabilo, je schopné dodávať energiu do siete a tým fungovať skoro ako ďalšia batéria. Na správne fungovanie tohto systému je vhodné

využívať riadenie, ktoré ponúka tento blok – pre účely simulácie sme ho však vypli a prednastavili žiadané správanie bloku predom na čas simulácie. Tým sme vytvorili možné extrémne záťažné scenáre. V schéme sa samozrejme nachádza aj úložisko energie a všetky meracie prístroje aby sme boli schopní presne určiť stavy v rámci mikrogridu.

1.3 Tretí mikrogrid

Pri tretom mikrogride budeme rovnako simulovať rôzne scenáre pre konkrétnu skupinu zariadení, ktoré vyrábajú a spotrebúvajú elektrinu. Táto skupina zariadení predstavuje domácnosť, na rozdiel od predchádzajúcich, tu budeme využívať najmä obojsmernú nabíjaciu stanicu pre elektrické vozidlá. Klasická nabíjacia stanica pre elektrické vozidlá spotrebúva energiu tým, že vozidlá dobíja, obojsmerná dokáže okrem toho elektrinu aj sama vyrábať. Preto budeme pozorovať stav batérie, akonáhle začne stúpať nad želanú (nastaviteľnú) hodnotu, energiu budeme posúvať do domácnosti a následne môžeme nadbytočnú predávať.



Obrázok 3: Simulačný model tretieho mikrogridu

Na obrázku 3 vidíme schému predstavujúcu domácnosť, kde ako zdroje energie figurujú dve veterné turbíny do ktorých vstupuje rýchlosť vetra. Táto hodnota značne ovplyvňuje výrobu elektrického napätia, preto bude vhodným vstupom do nášho mikrogridu spolu s nabíjacou stanicou keď je v režime nad želanou hodnotou (SoC [%]).

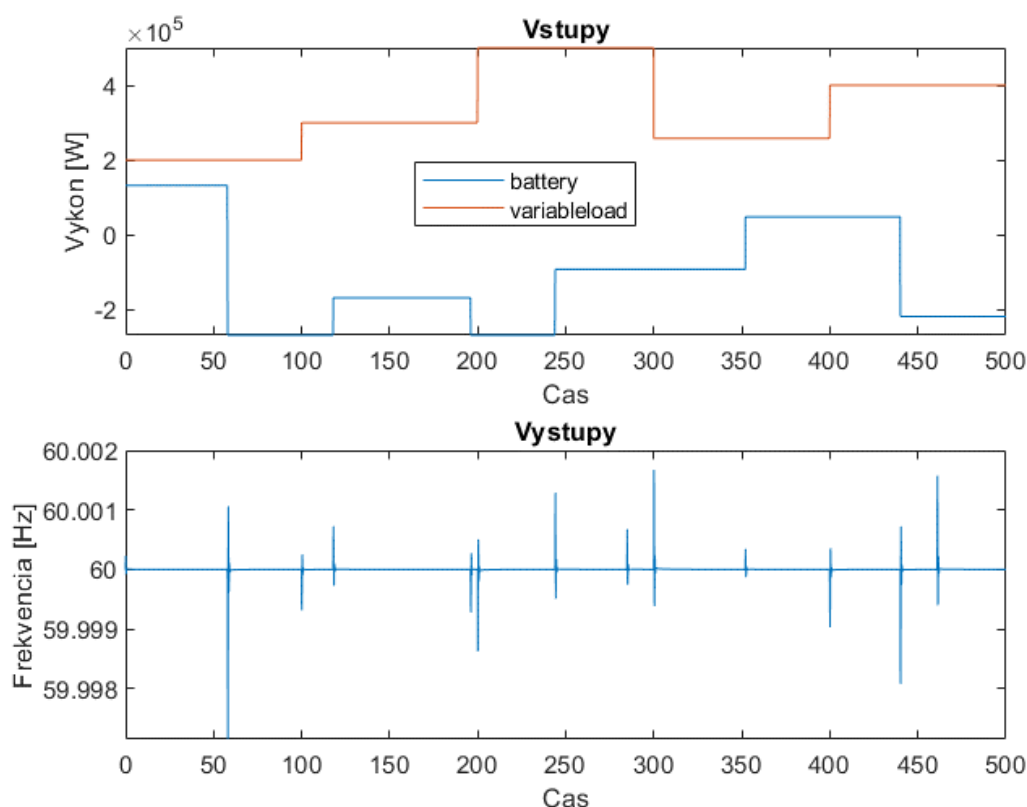
Naopak spotrebu elektrickej energie predstavujú spotrebiče v domácnosti (premenlivá záťaž) a nabíjacia stanica v režime kedy sa auto nabíja (hodnota SoC pod želanou hranicou). Medzi týmito dvoma módmami sa budeme prepínať pomocou premennej control, ktorá je vstupom do nabíjačky. Zároveň bude aj špeciálnym vstupom pre neurónový model, keďže je to deterministický ukazovateľ stavu nabíjačky (vybíja alebo nabíja). Aby sme vedeli vymodelovať rôzne scenáre, budeme používať náhodnú hodnotu pre túto premennú, ktorá sa bude generovať v čase. Keďže sme si dokázali túto elektrickú nabíjačku vymodelovať celú, vieme sledovať rôzne zaujímavé veličiny, ale pri tomto mikrogride budeme sledovať najmä hodnoty napätia jednotlivých fáz.

2 Simulačné výsledky mikrogridov

V rámci jednotlivých gridov nás bude vždy zaujímať závislosť výstupov od variabilných častí mikrogridov. Každý simulačný model je špecifický a aj vhodnejší/nevhodnejší na aproximácie jednotlivých výstupných veličín. Pri prvom gride sme sa rozhodli sústrediť sa na frekvenciu siete, v druhom modeli na výkonovú bilanciu siete a pri treťom sa pozrieme na vývoj napätia jednej z fáz.

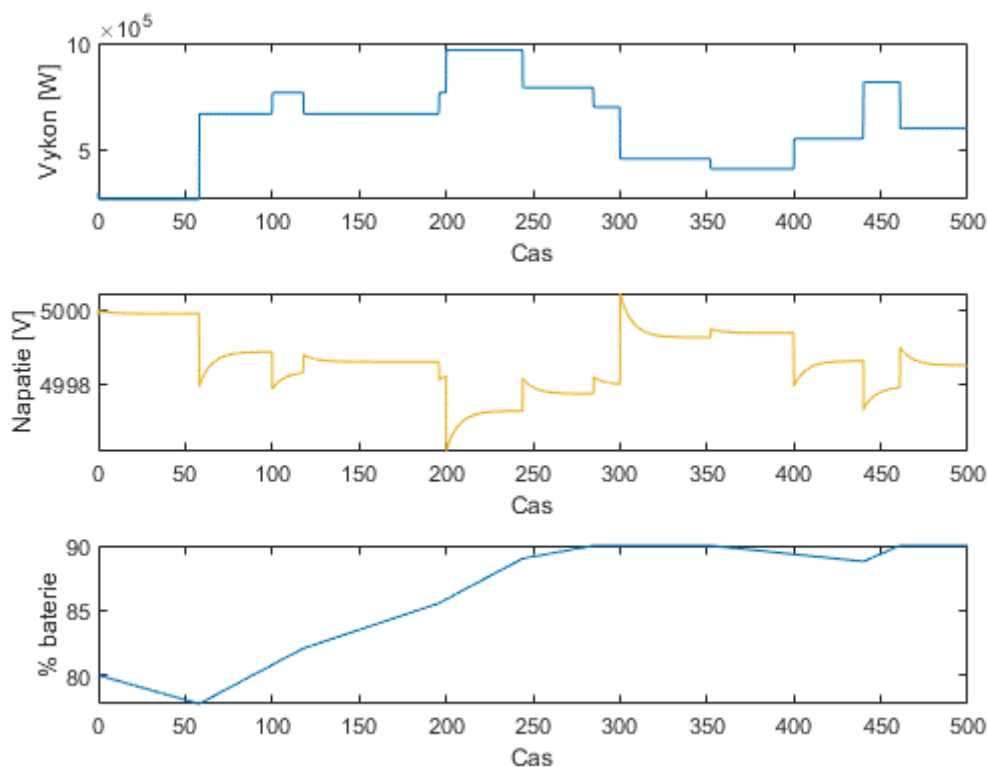
2.1 Prvý mikrogrid

Ako sme opísali v úvodnej kapitole, simulačne nameriame frekvenciu v sieti počas celého experimentu, tá môže mierne kolísať v okolí 60Hz (teda jej nominálnej hodnoty). Všetky tieto výkyvy sa však budú dať dobre aproximovať pomocou NARX modelu a tak do budúcnosti vedieť predvídať, za akých podmienok k takýmto výkyvom príde a následne upraviť riadenie tak, aby boli výkyvy minimalizované.



Obrázok 4: Namerané výstupy na základe vstupov

Vstupy sú dva – výkonové profily pre batériu a variabilnú záťaž – rezidenčnú zónu. Pre zaujímavosť uvádzame aj obrázok 5 – ostatné merané veličiny v rámci gridu:




Obrázok 5: Ostatné merané veličiny

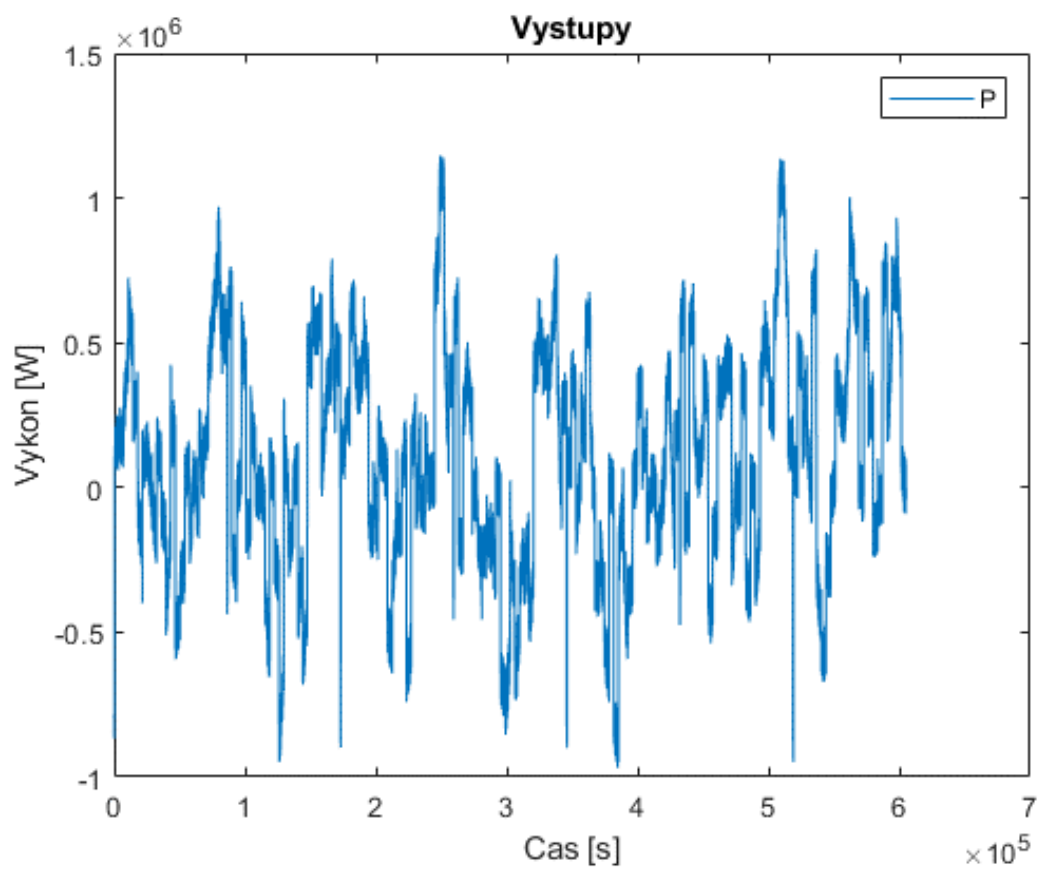
Tento obrázok sme tu umiestnili najmä kvôli tomu, že pri tvorbe neurónového modelu môžeme využiť aj ďalšie závislosti okrem už použitých – napríklad výkonový profil batérie možno nahradiť jej percentom nabitia, či nemusíme tvoriť model pre frekvenciu, ale napríklad pre výkon, či napätie.

2.2 Druhý mikrogrid

Pri druhom mikrogride budeme skúmať ako vplývajú variabilné časti na vývoj výkonu v sieti. Keďže v gride je zaradený blok V2G, ktorý disponuje riadením, je nutné toto riadenie vypnúť (aby sme boli schopní „prikázať“ bloku správať sa podľa našich požiadaviek a nie požiadavok siete) – inak by sa toto riadenie snažilo kompenzovať výkony v rámci siete, my však chceme nájsť možné defekty tak, aby model gridu čo najviac korešpondoval s realitou a v krízových situáciách disponoval dátami aj práve z takýchto situácií. V tomto prípade máme až 5 variabilných častí, pričom sa však jedná vždy o výkony a tak sa dá model v podstate sumovaním dodávaných výkonov zúžiť na jeden vstup. Ponechaním piatich vstupov môžeme sledovať aj vplyv jednotlivých zložiek, preto model ponecháme v tomto tvare.



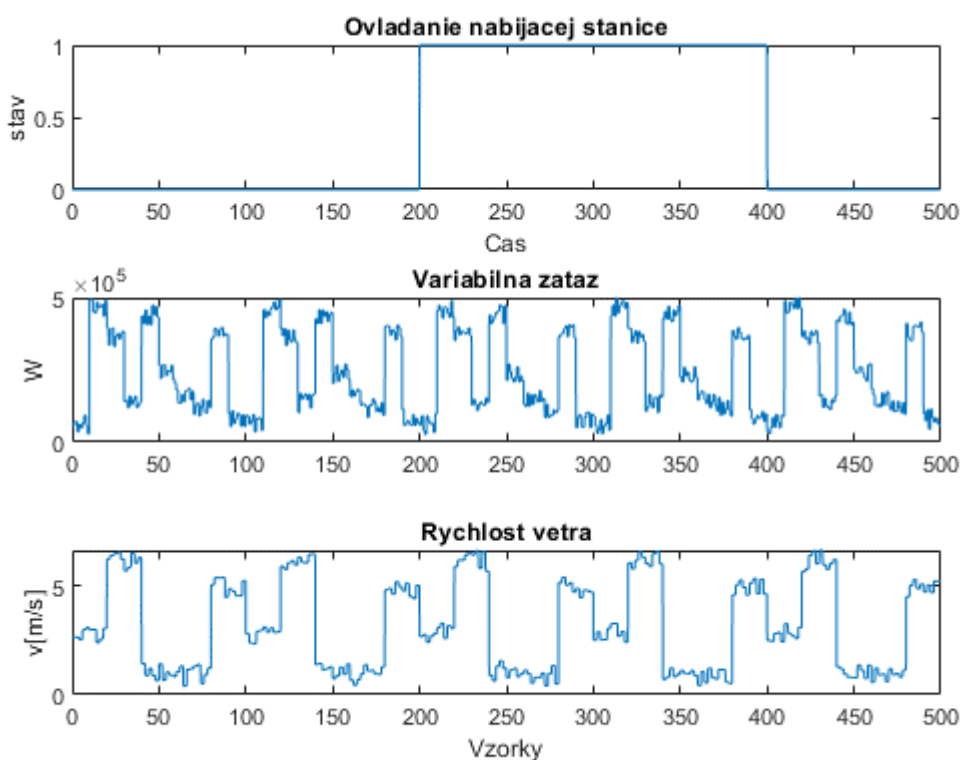
Obrázok 6: Vstupné variabilné veličiny do druhého mikrogridu



Obrázok 7: Výstupy (výkon v mikrogride)

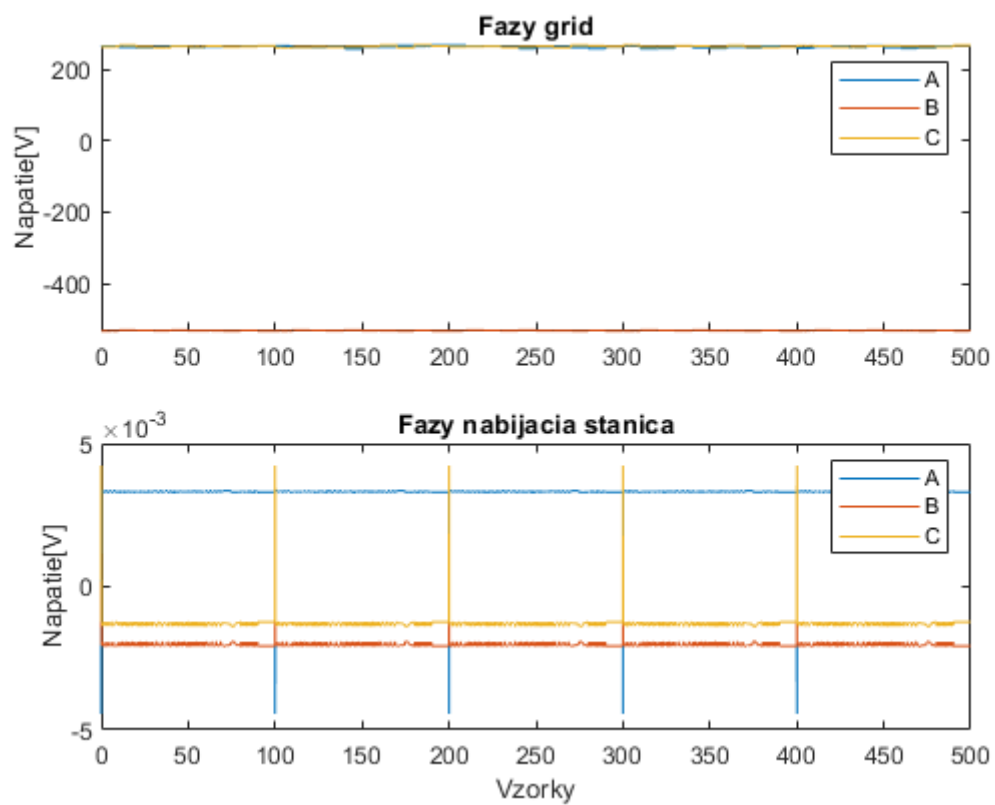
2.3 Tretí mikrogrid

Ako sme spomenuli v predošlej časti, v poslednom gride budeme hľadať súvislosť medzi variabilnými vstupmi a fázami napätia v rámci gridu. V tomto prípade budú vstupy tri – jedným z nich bude hodnota logickej premennej, ktorá rozhoduje o aktuálnom režime nabíjania/vybíjania auta zaparkovaného v garáži. Podobne, ako v predošlých gridoch sú ďalšími vstupmi variabilná záťaž – spotreba energie v domácnosti a variabilná zložka zelenej energie – v tomto prípade veternej. Pri tomto modeli však nevyužívame priamo dodanú energiu z veternej turbíny, ale meriame rýchlosť vetra.

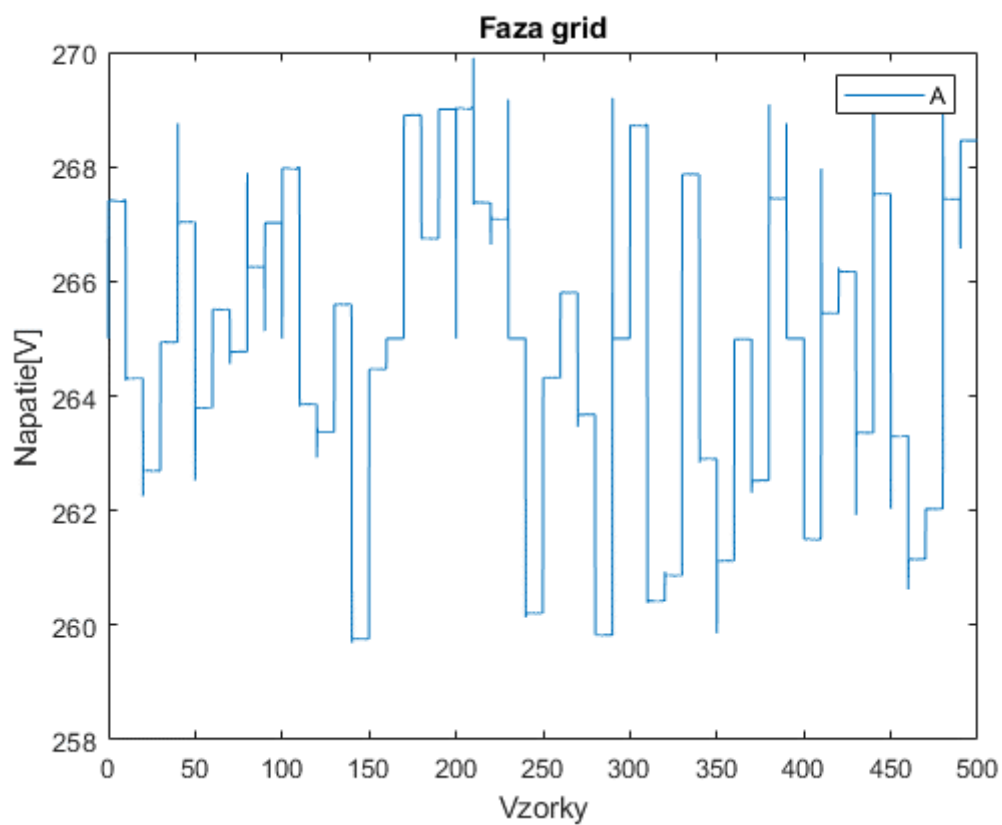


Obrázok 8: Vstupné variabilné veličiny do druhého mikrogridu

Ako výstupy môžeme považovať viaceré fázy – ich stavy vidíme na obrázku 9. Pri tvorení NARX modelu však ako výstup budeme považovať len fázu A, preto vykreslíme simulačné výsledky tejto fázy aj osobitne na obrázku 10.



Obrázok 9: Možné výstupy z mikrogridu



Obrázok 10: Výstupná fáza A

3 Neurónové modely

Ako sme spomínali v predošlých kapitolách, budeme sa zaoberať tvorbou modelov pre skúmané závislosti v mikrogridoch. Presné modely môžu slúžiť ako aproximácia reálneho systému a pri návrhu riadenia systému sú častokrát lepšie využiteľné ako reálne systémy. Mikrogridy sú zložité systémy a preto klasické aproximačné metódy pre modely neponúkajú dostatočnú presnosť. Preto na tvorbu modelov budeme používať **NARX**. Je súčasťou Deep Learning toolboxu v MATLABe.


3.1 NARX

NARX (z angl. non-linear autoregressive network with exogenous inputs) je rekurentná dynamická sieť, tvorená viacerými vrstvami – pričom vrstvy môžu byť rôzne poprepájané. NARX je postavený na základe lineárneho ARX modelu. Výstup definujeme nasledovne:


$$y(t) = f[y(t-1), y(t-2), \dots, y(t-n), u(t-1), u(t-2), u(t-m)] \quad (1)$$

kde pomocou neurónovej siete hľadáme funkciu f , v ktorej vystupujú ako premenné minulé vzorky výstupu y , a taktiež vzorky u . Pri modeli si tak vieme navoliť, koľko vstupných/výstupných vzoriek má vplývať na nový výstup siete. Ďalším voliteľným parametrom je počet skrytých neurónov – spomínali sme, že NARX je viacvrstvová sieť, práve skrytú vrstvu tvorí teda určitý počet vopred stanovených skrytých neurónov. Ich pridaním získame možnosť presnejšej aproximácie, no za cenu vyššieho výpočtového výkonu. Taktiež, ak zvolíme príliš veľa skrytých neurónov, optimálne nastavenie parametrov siete sa nemusí vôbec nájsť. Konkrétnym konfiguráciám siete sa budeme venovať neskôr.

3.2 Architektúra



Obrázok 11: Sériovo - paralelná



Obrázok 12: Paralelná

Sériovo – paralelná (otvorená): ako vstupy do modelu idú vzorky vstupov a taktiež vzorky známeho (nameraného) výstupu. Nevýhodou je, že je nemožná na použitie pri neznámych výstupných/nových dátach.

Paralelná (uzatvorená): ako vstupy do modelu idú vzorky vstupov a ako vzorky výstupov sa používajú minulé výstupy, ktoré už vyšli zo samotného modelu v predošlých krokoch. Dá sa použiť pri neznámych výstupných alebo nových dátach, avšak v prípade nepresnosti modelu sa chybovosť modelu rapídne zvyšuje.

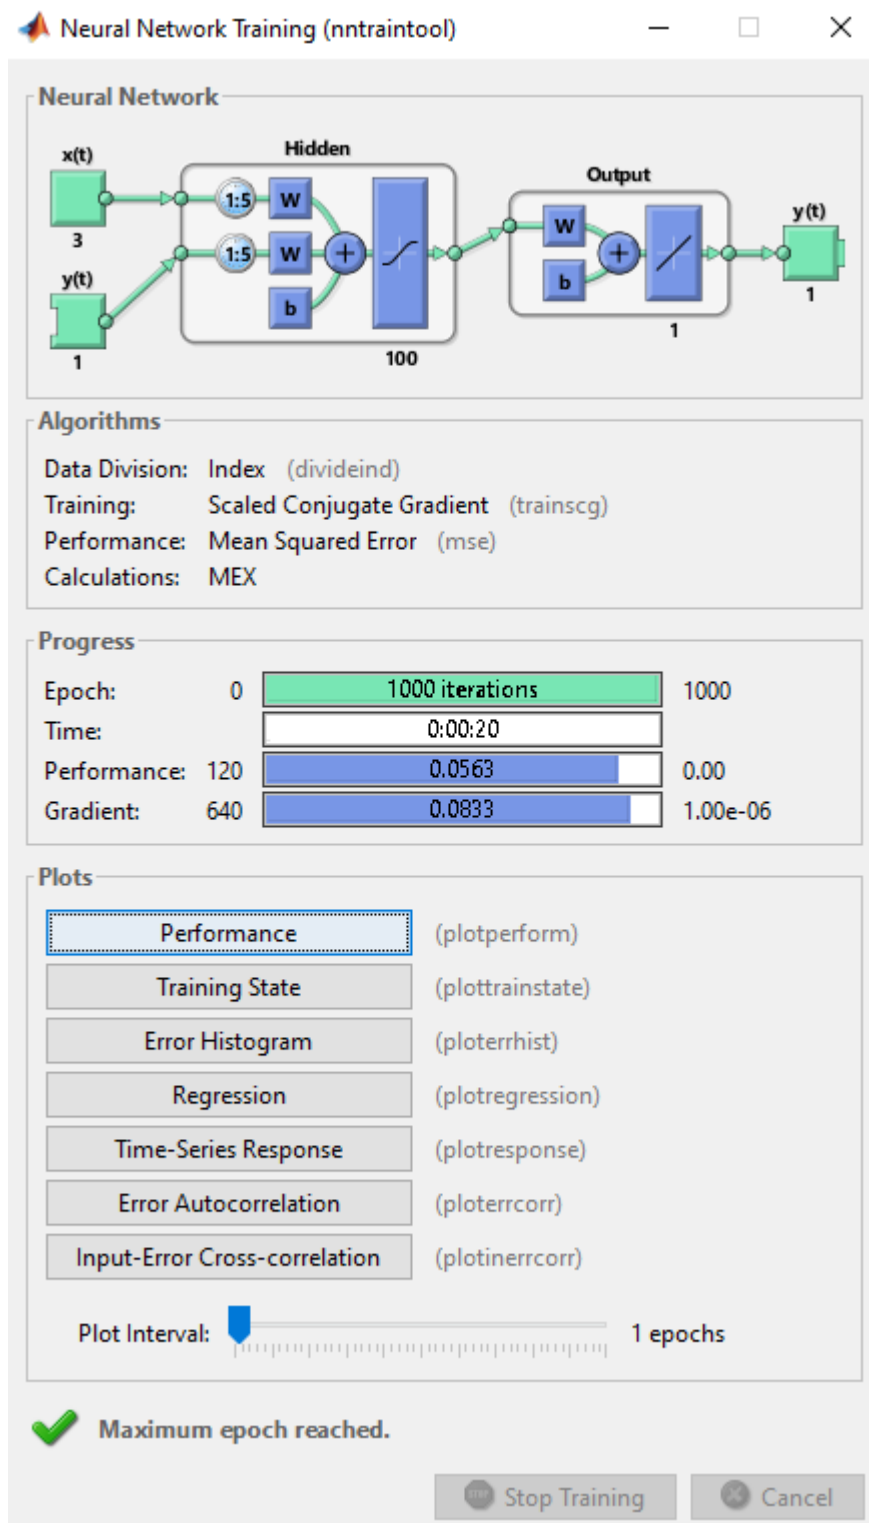
Už z definície je pre nás potrebné nájsť čo najlepší model paralelnej štruktúry, keďže chceme použiť model na nové dáta. Trénovanie NARX však prebieha na sériovo – paralelnej a keď je takýto model presný, vieme ho premeniť na paralelný.

3.3 Trénovanie NARX

V predošlej časti sme hovorili o troch základných parametroch pri NARX, ktoré vyplývali priamo zo vzťahu pre výpočet nového výstupu. Okrem týchto parametrov však musíme pre správne natrénovanie nájsť aj správne trénovacie parametre. Medzi ne patrí:

- **cieľ** – pri akej presnosti môže trénovanie skončiť, model je už dostatočne dobrý
- **počet epoch** – maximálne koľko trénovacích epoch chceme nechať trénovať
- **trénovacia funkcia** – správny výber môže urýchliť proces, či zlepšiť výsledky
- **minimálny gradient** – minimálny gradient pri gradientovej trénovacej funkcii

Na záver potrebujeme pred trénovaním rozdeliť dáta – na trénovacie, testovacie a prípadne validačné. V tomto prípade však validačné dáta nebudeme používať, keďže budeme NARX chcieť používať ako *prediktor* a potrebujeme nájsť optimálny model s čo najlepšou presnosťou. Preto trénovacie a testovacie dáta rozdelíme v pomere 1:1 (celkový dataset na polovicu). Pre jednoduchosť použijeme indexové rozdelenie, kde prvá polovica dát bude určená na trénovanie a druhá na testovanie. Testovacie dáta budeme testovať na oboch architektúrach – na otvorenej aj na uzatvorenej, pričom nás najviac bude zaujímať presnosť na uzatvorenej architektúre. V každom datasete sme sa pokúsili nájsť v testovacej časti aj také hodnoty vstupov, ktoré boli pre model úplne nové, tak, aby sme overili správnosť natrénovania. Trénovanie spustíme príkazom *train* a automaticky sa spustí NNtraintool, ktorý je taktiež súčasťou Deep learning toolboxu. Ako vyzerá, vidíme na nasledujúcom obrázku. Vidíme, že okrem štruktúry siete v hornej časti ponúka taktiež trénovacie parametre, alebo možnosť vykresliť niekoľko špecifických grafov, pomocou ktorých je možné vyhodnotiť kvalitu natrénovania NARX.



Obrázok 13: NN traintool

Pri vyhodnocovaní kvality budeme používať kritérium MSE, čiže strednú kvadratickú chybovosť modelu (porovnáva známe výstupy s výstupmi modelu). Graf vývoja chyby vieme vyvolať pomocou GUI (Obrázok 13) kliknutím na okienko *performance*.

3.4 Hľadanie optimálnej štruktúry

Každý model je špecifický a preto sme pre každý prípad hľadali optimálnu štruktúru. Čo funguje dobre pri jednom modeli, môže pri ďalšom byť kompletne nefunkčné. Preto sme vytvorili skript, ktorý vyskúša všetky kombinácie z preddefinovaných a podľa presnosti modelu vyberie najlepšiu. Tabuľka ukazuje všetky testované kombinácie:

<i>Parameter</i>	Počet minulých hodnôt vstupov (n)	Počet minulých hodnôt výstupov (m)	Počet skrytých neurónov (hn)
<i>Možné varianty</i>	1,4,7,10	1,4,7,10	5,7,10,20,50,100

Tabuľka 1: Možné parametre NARX modelu

Ako sme spomínali, najviac nás zaujíma presnosť v uzatvorenej (paralelnej) štruktúre. Pre zaujímavosť však budeme hľadať aj najlepšie modely podľa ďalších kritérií – presnosti na tréningových dátach, alebo presnosti na testovacích dátach v otvorenej slučke. Zároveň ukážeme priebeh tréningu najlepšieho modelu pri uzavretej slučke.

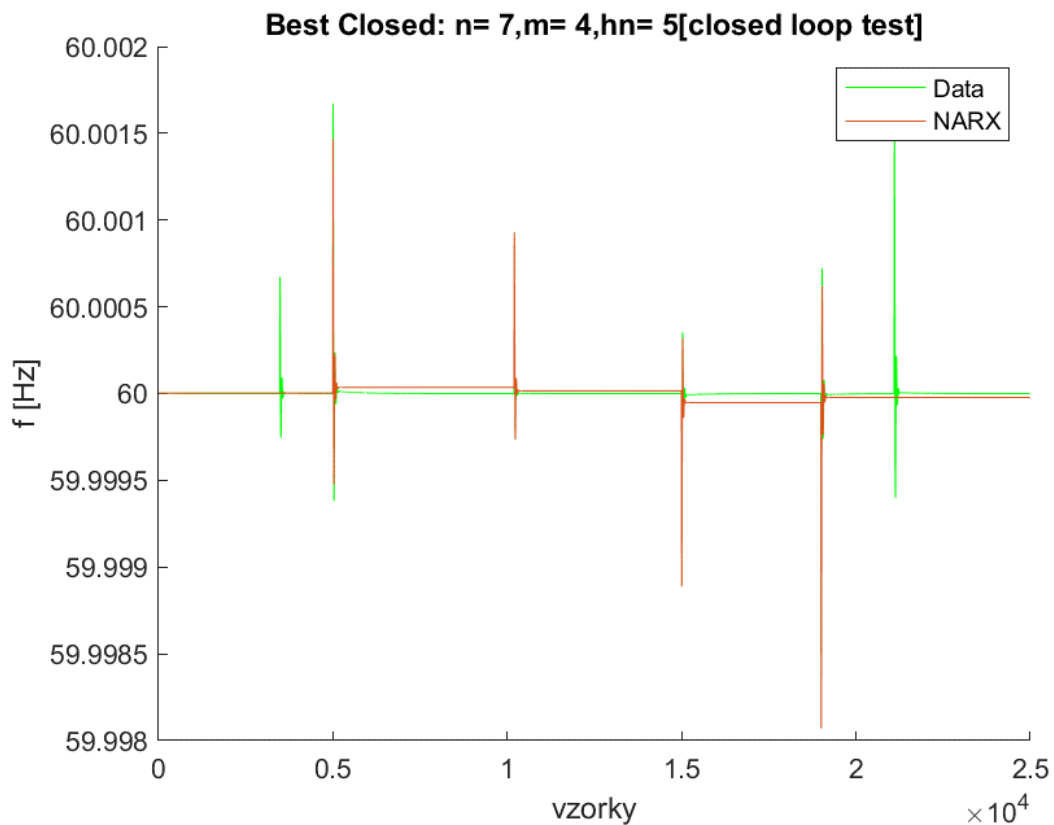
3.5 Model prvého gridu

Parametre (n, m, hn)	Presnosť - uzavretá	Presnosť - otvorená	Presnosť - tréningové
7, 4, 5	$2,72 \cdot 10^{-9}$	$7,19 \cdot 10^{-12}$	$5,13 \cdot 10^{-14}$
10, 10, 5	$1,93 \cdot 10^{-9}$	$6,91 \cdot 10^{-12}$	$3,65 \cdot 10^{-15}$
10, 7, 20	$1,09 \cdot 10^{-5}$	$1,81 \cdot 10^{-8}$	$9,78 \cdot 10^{-16}$


Tabuľka 2: Presnosti pri rôznych parametroch modelu prvého gridu

Podľa tabuľky 2 vidíme presnosti jednotlivých modelov. Vidíme, že najvyššia presnosť tréningu negarantuje automaticky aj najlepšiu presnosť pri uzavretej či otvorenej slučke na testovacích dátach. Tento jav môžeme nazvať pretrénovanosť siete.

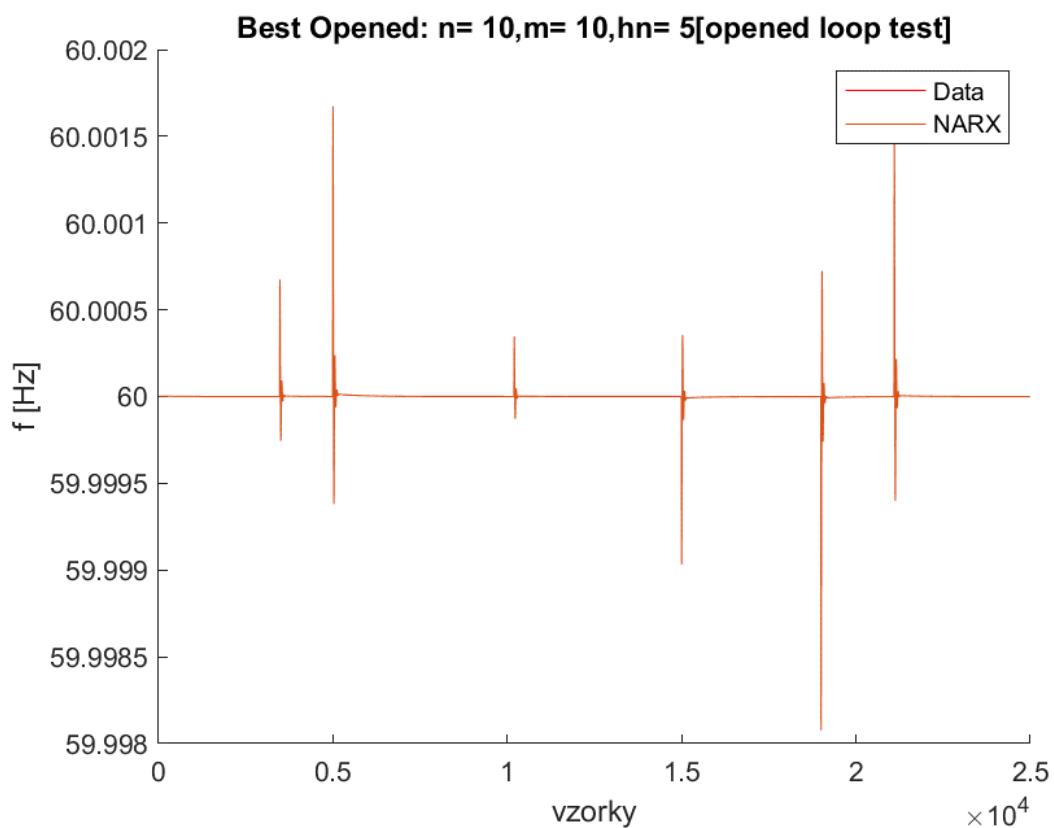
Všeobecne môžeme povedať, že pri modeli prvého mikrogridu bude kľúčom k úspechu použitie viacerých minulých hodnôt (vstupov, výstupov). Je to spôsobené tým, že model sa venuje frekvencii – na zachytenie zmien frekvencie je potrebné znížiť periódu vzorkovania na čo najmenšiu. Preto v tomto prípade je viacero vzoriek síce relatívne malá zmena v čase, no model tým pádom disponuje presnejšími dátami o výchylkách frekvencie, ktoré sú samozrejme veľmi malé a ťažko zachytávateľné.



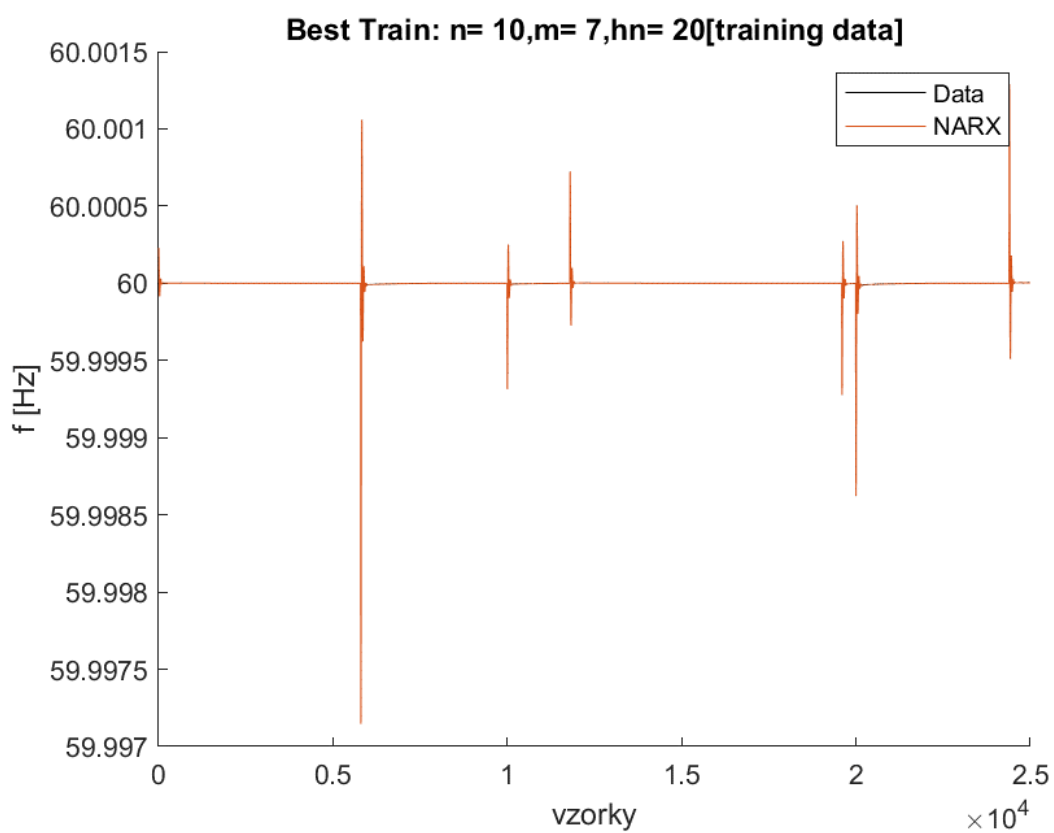
Obrázok 14: Najlepší model pre testovacie dáta s uzavretou slučkou



Obrázok 15: Priebeh trénovania najlepšieho modelu s uzavretou slučkou



Obrázok 16: Najlepší model pre testovacie dáta s otvorenou slučkou



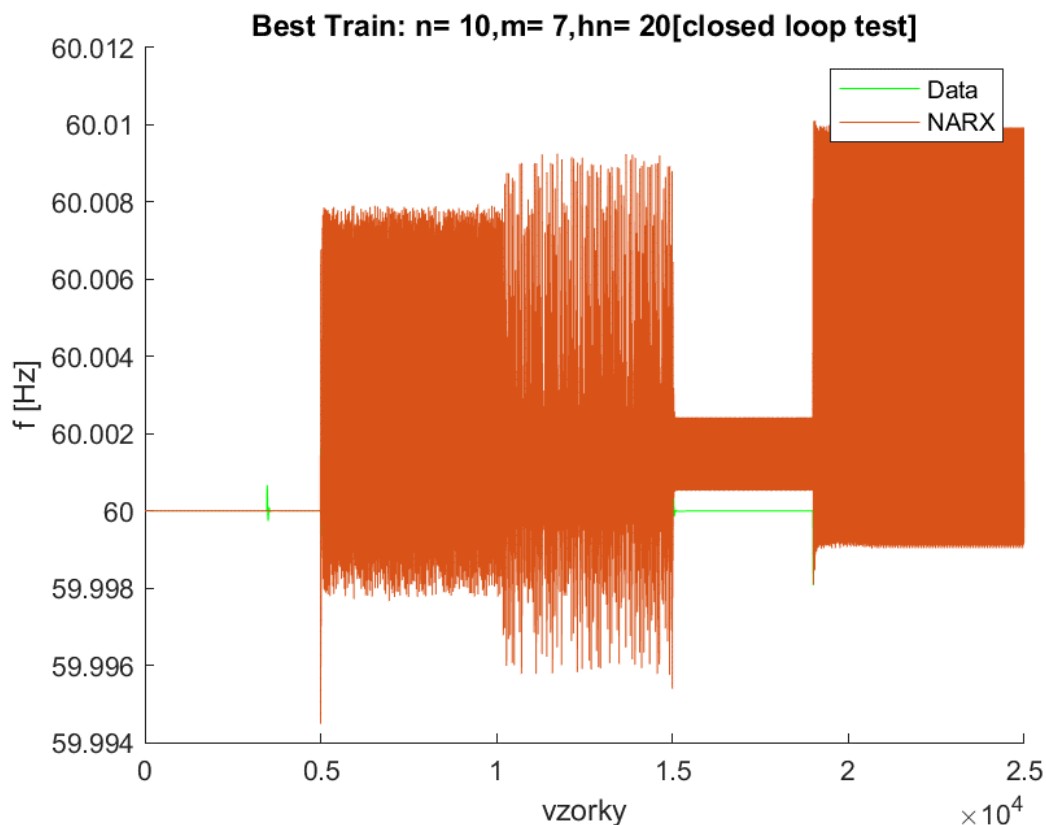
Obrázok 17: Najlepší model pre trénovacie dáta

Na Obrázok 14 vidíme porovnanie modelu s uzavretou slučkou s reálne nameranými dátami – neprichádza k žiadnemu vážnemu rozkolísaniu a model dokáže veľmi presne aj predvídať výkyvy frekvencie, keďže nezachytil len prvý a posledný výkyv frekvencie a navyše nepridal žiadny falošný výkyv, čo môžeme hodnotiť pozitívne.

Na Obrázok 15 je priebeh trénovania modelu, ktorý vykázal najväčšiu presnosť pri použití uzavretej slučky. Trénovanie prebehlo, podobne ako pri všetkých modeloch na 500 epochách, pričom vidíme, že majoritná zmena presnosti nastávala v prvých epochách, avšak presnosť modelu postupne konvergovala aj ďalej, až po päťstú epochu.

Obrázok 16 poukazuje na odozvu najlepšieho modelu v otvorenej slučke pri použití testovacieho datasetu. V tomto prípade boli veľmi presne zachytené všetky výkyvy a taktiež model nepriniesol žiadnu falošnú zmenu frekvencie. Problémom však samozrejme ostáva, že pri použití NARX v reálnom svete nebudeme vopred disponovať správnymi dátami a tak použitie otvorenej štruktúry je v podstate nemožné.

Na Obrázok 17 je najlepší model pre trénovacie dáta. Ten poukazuje na absolútnu presnosť modelu voči reálnym dátam z trénovacieho datasetu. Ako sme však spomínali, veľmi vysoká presnosť na trénovacích dátach neznamená automaticky úspech – pre porovnanie pridávame výsledok v uzavretej slučke pre tento model (obrázok 18):



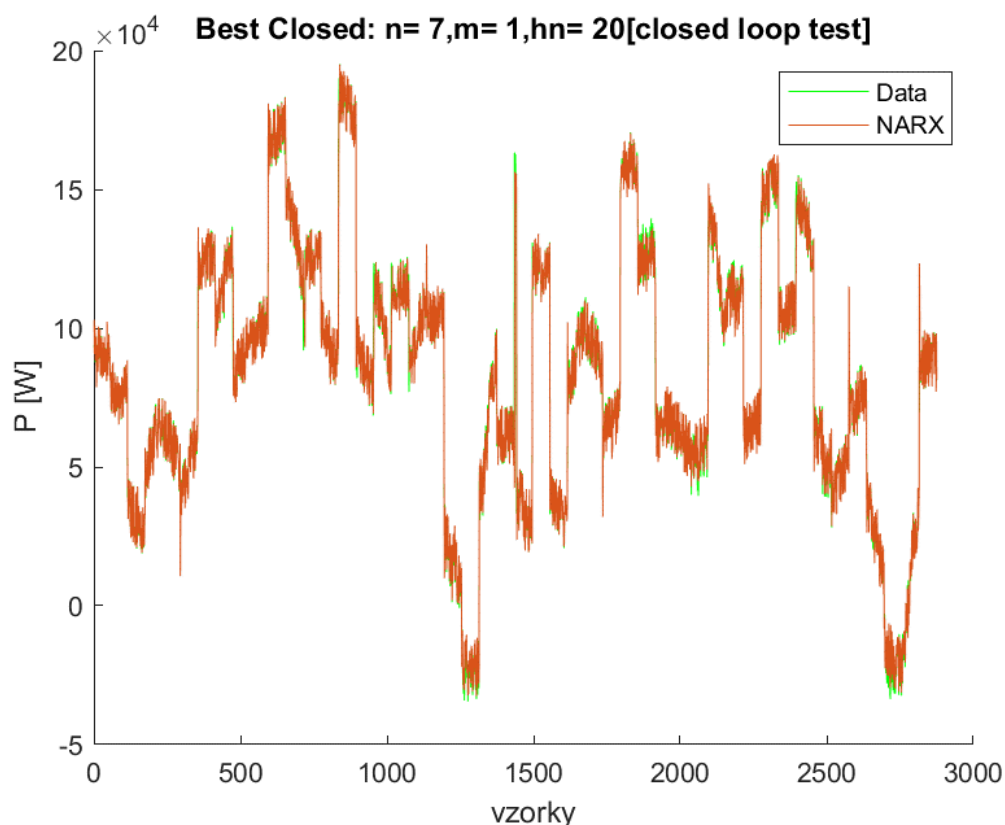
Obrázok 18: Uzavretá slučka pre najlepší model na základe trénovacej presnosti

3.6 Model druhého gridu

Parametre (n, m, hn)	Presnosť - uzavretá	Presnosť - otvorená	Presnosť - trénovacie
7, 1, 20	$1,38 \cdot 10^7$	$1,14 \cdot 10^7$	$3,93 \cdot 10^6$
10, 7, 5	$2,51 \cdot 10^{12}$	$9,67 \cdot 10^6$	$5,81 \cdot 10^6$
10, 4, 20	$8,53 \cdot 10^{12}$	$1,78 \cdot 10^8$	$4,41 \cdot 10^5$


Tabuľka 3: Presnosti pri rôznych parametroch modelu druhého gridu

Už na prvý pohľad na tabuľku 3 vidíme, že chybovosť je rádovo vyššia oproti predošlému prípadu, no treba sa pozrieť aj v akých rádoch sa pohybujú jednotlivé modely – kým výkyvy frekvencie v predošlom prípade boli v rádoch tisícín, tu máme skoky výkonov v stovkách kilowattov, takže rádoch stotisícov – tak samozrejme v tomto prípade aj menšia chyba znamená na prvý pohľad väčšiu hodnotu.

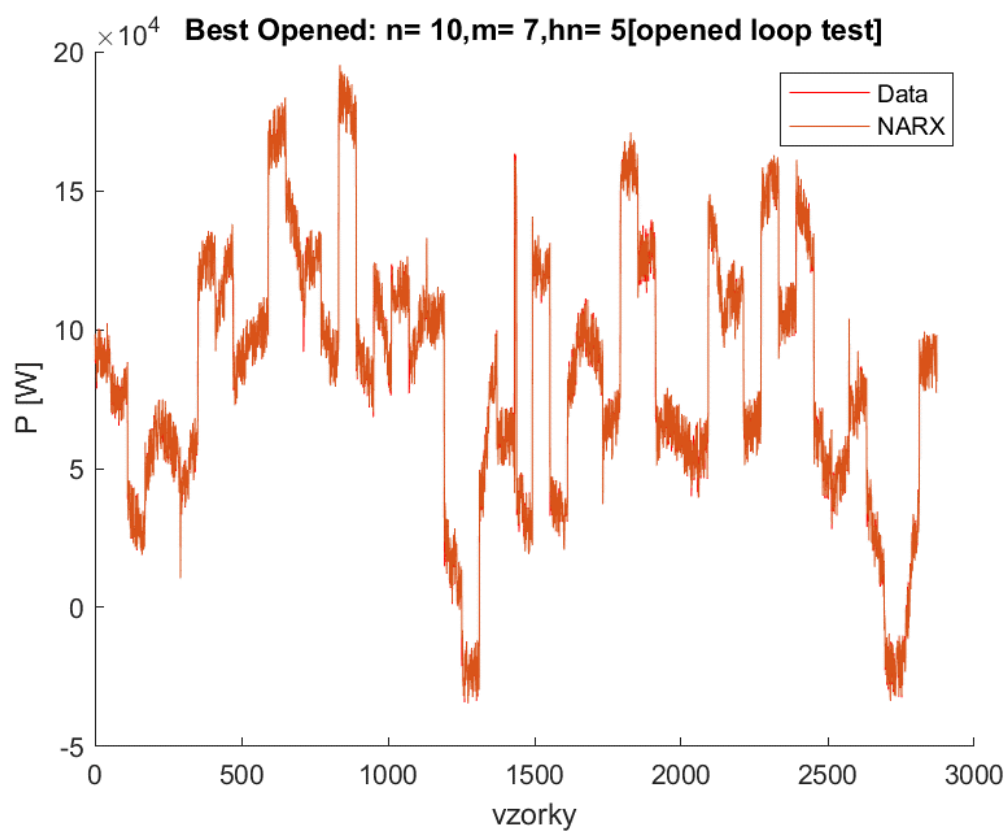


Obrázok 19: Najlepší model pre testovacie dáta s uzavretou slučkou

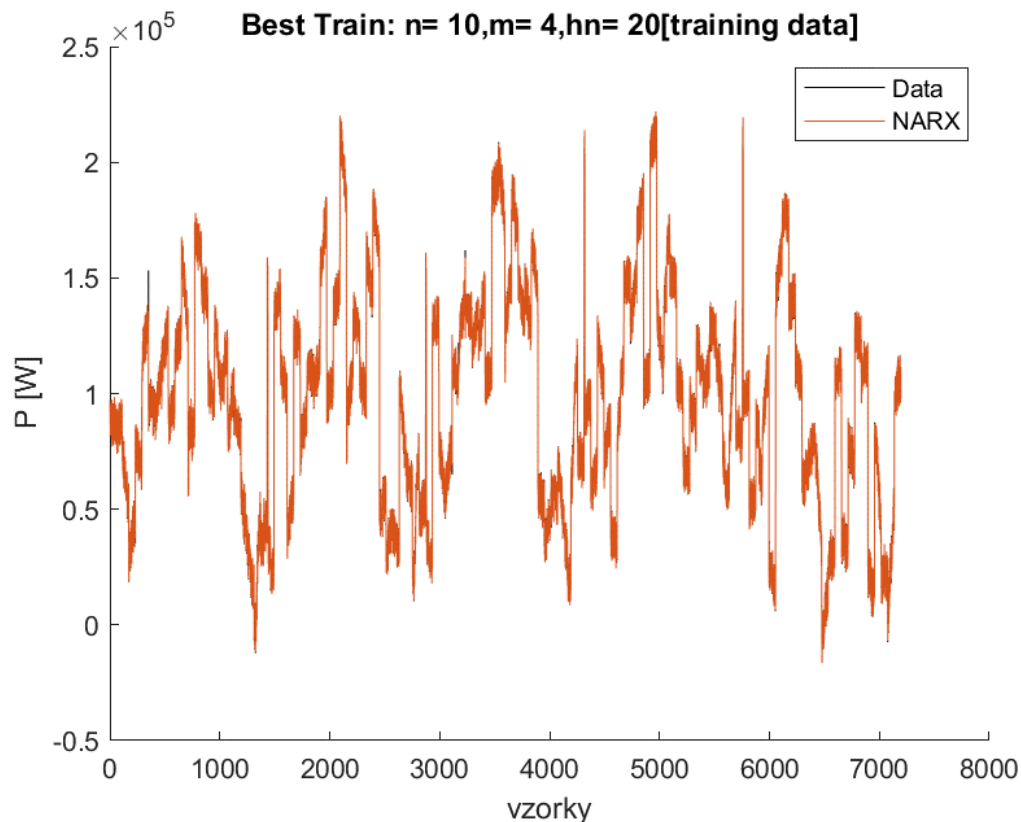
Už však na prvý pohľad vidno, že model relatívne presne kopíruje skoky, najmä čo sa časovej odozvy týka. Rozdiel tisíc wattov v tomto prípade už nebude hrať až takú rolu, keď budeme vedieť vopred predvídať, kedy ku skoku príde a budeme schopní reagovať.



Obrázok 20: Pribeh trénovania najlepšieho modelu s uzavretou slučkou



Obrázok 21: Najlepší model pre testovacie dáta s otvorenou slučkou



Obrázok 22: Najlepší model pre trénovacie dáta

Obrázok 19 sme síce opísali aj vyššie, pri porovnaní s otvorenou štruktúrou na Obrázok 21 však stále vyznieva relatívne presný, napriek tomu, že pri otvorenej štruktúre vidíme už minimum nepresných výkyvov a samozrejme, ako pri uzavretej štruktúre je časová odozva presná. Pri všetkých modeloch je perióda vzorkovania 1s, to znamená, že každá vzorka je vlastne zároveň aj 1s – tým pádom vieme odhadovať aj v akých hodinách prišlo k najväčším výkyvom pomerne jednoducho.

Na Obrázok 20 je priebeh trénovania najlepšieho modelu s uzavretou slučkou, vidíme postupnú konvergenciu presnosti tréningových dát, ktorá by pokračovala aj ďalej, avšak za cenu znefunkčnenia uzavretého modelu a tým stratu výnimočnosti danej konfigurácie. Obrázok 22 ukazuje na trénovaciu presnosť najlepšieho modelu v tomto ohľade. Pri pohľade na Tabuľka 3 vieme povedať, že to znamená obrovskú nepresnosť pre uzavretú slučku, takže je pre nás tento model nepoužiteľný (chyba je rádovo 10^{12}).

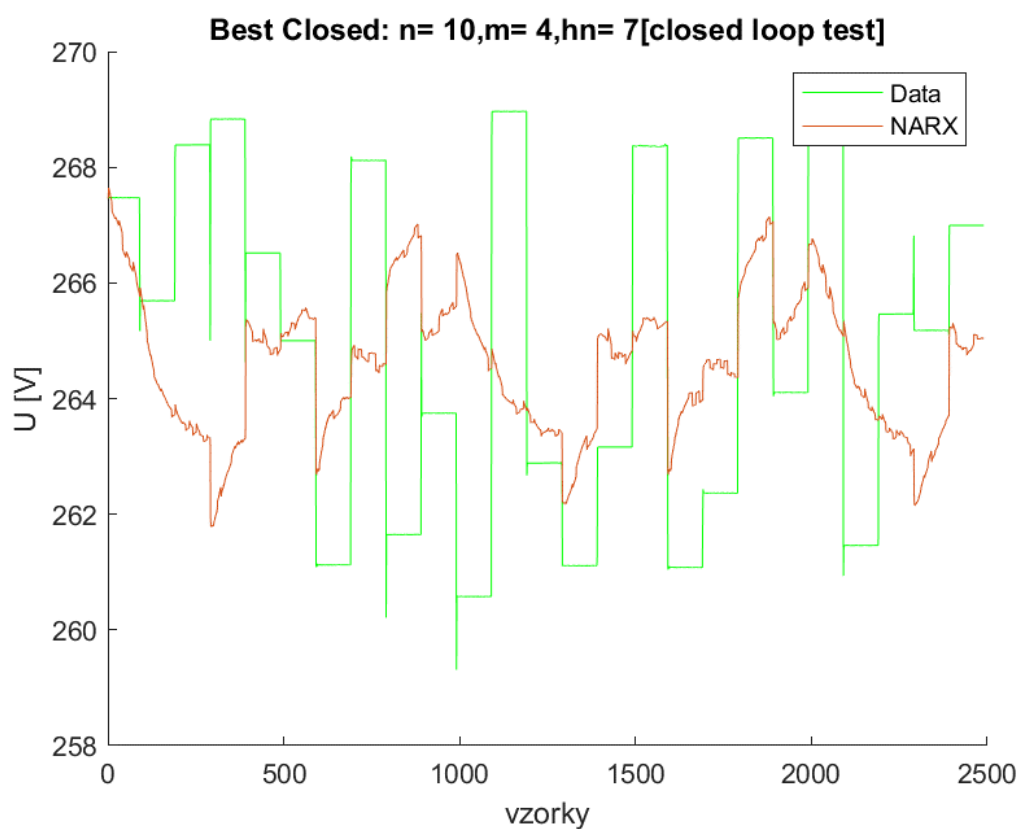
Model s konfiguráciou 7,1,20 je v tomto ohľade spoľahlivý – podľa nej sa spolieha len na poslednú vzorku výstupu, no zato až 7 posledných vstupných. Presnosť modelu garantuje 20 skrytých neurónov.

3.7 Model tretieho gridu

Parametre (n, m, hn)	Presnosť - uzavretá	Presnosť - otvorená	Presnosť - tréningové
10, 4, 7	8,1278	0,1991	0,0833
7, 4, 7	11,0975	0,1942	0,0819
4, 4, 50	16,2937	0,2133	0,0803

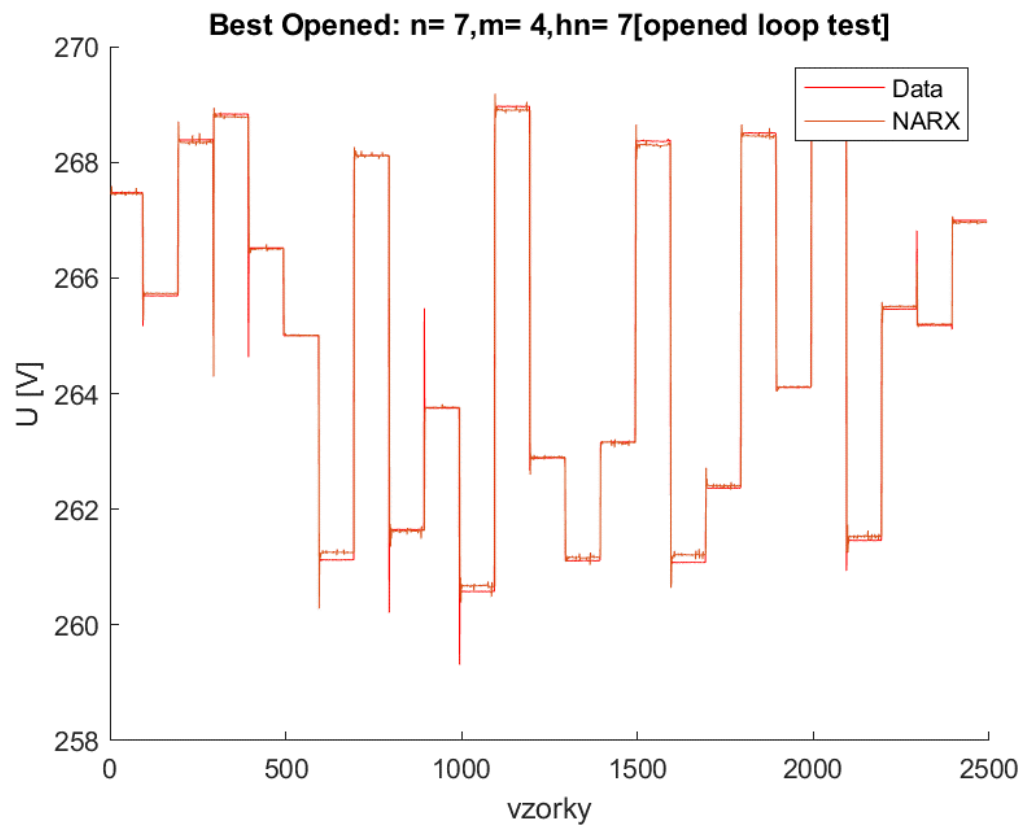
Tabuľka 4: Presnosti pri rôznych parametroch modelu tretieho gridu

Už na základe tabuľky 4 vidíme, že presnosť uzavretého modelu je diametrálne horšia ako presnosti otvorenej slučky alebo tréningových dát. Pri tomto modeli teda žiaľ nemôžeme použiť uzavretú slučku (Obrázok 23):




Obrázok 23: Najlepší model pre testovacie dáta s uzavretou slučkou

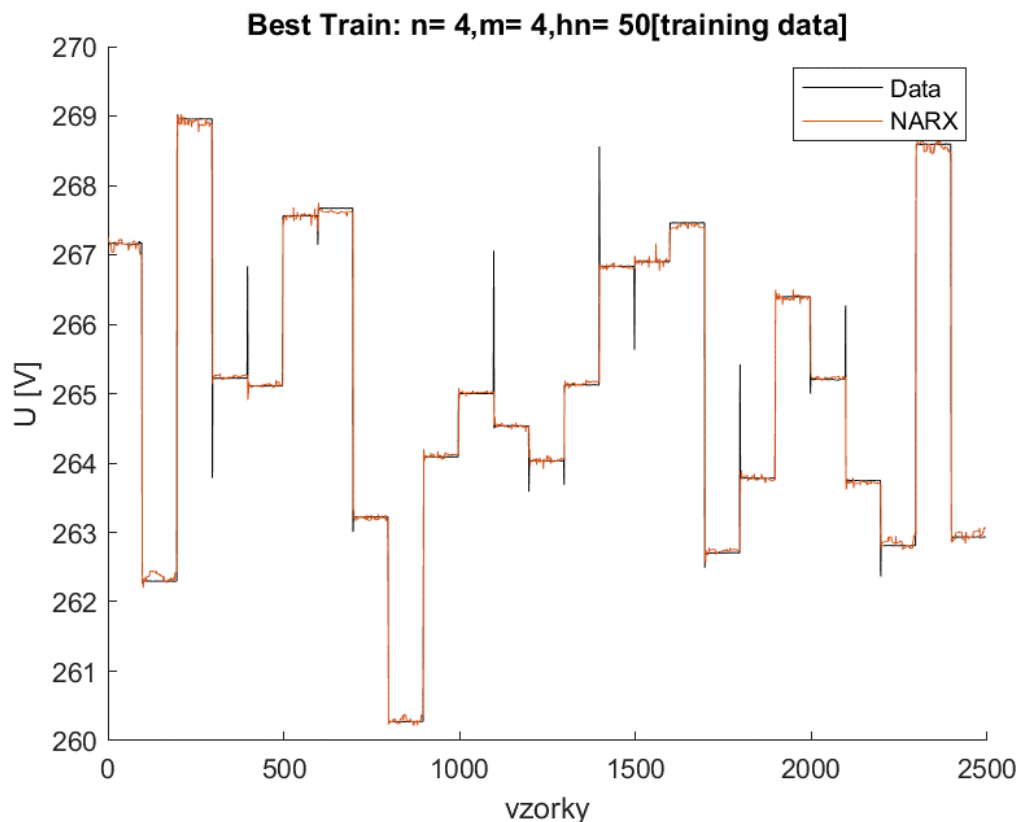
Z existujúcich variánt konfigurácii neexistuje taká, pri ktorej by mohol model fungovať. Preto aj priebeh tréningovania ukážeme až z najlepšieho otvoreného modelu na testovacích dátach (Obrázok 25).



Obrázok 24: Najlepší model pre testovacie dáta s otvorenou slučkou



Obrázok 25: Priebeh trénovania najlepšieho modelu s otvorenou slučkou



Obrázok 26: Najlepší model pre trénovacie dáta

Obrázok 24 znázorňuje najlepší model pre testovacie dáta v otvorenej slučke. Presnosť modelu je na veľmi dobrej úrovni, podľa obrázka vidíme, že model má problém len s veľmi krátkymi výkyvmi napätia. V podstate je však schopný presne odhadovať hodnoty napätia vo väčšine času. V porovnaní s uzavretou slučkou je to výrazné zlepšenie, no zároveň možno až nerealizovateľná komplikácia v použití takéhoto modelu na reálnu aplikáciu.

Obrázok 26 funguje na trénovacích dátach, kde vidíme mierne lepšiu presnosť ako v predošlom prípade. Opäť má však rovnaký problém – krátke výkyvy napätia. Všetky modely podľa tabuľky disponujú štyrmi poslednými krokmi pre výstupy, avšak perióda vzorkovania je zrejme veľká a preto model nevie adekvátne zareagovať. Znížením periódy by sa zrejme zvýšila schopnosť zachytávať aj tieto výkyvy, no pri uzavretom modeli by sme stále narazili na problém s veľkou nepresnosťou.

4 Riadenie projektu

Po rozdelení tímov bol za vedúceho tímu zvolený **Bc. Marko Chylík**. Jeho úlohou bolo zostrojiť stručný plán podľa ktorého bude projekt vypracovaný a zároveň rozdeliť úlohy. V nasledujúcej tabuľke stručne naznačíme úlohu každého člena tímu:

Riešiteľ	Úlohy
Bc. Marko Chylík	Vedúci, výskum, návrh riešení 1. a 2. gridu
Bc. Jakub Lulák	Návrh riešenia 3. gridu, modelovanie, dokumentácia
Bc. Filip Iglarčík	Simulácie, garant realizovateľnosti v reálnom prostredí
Bc. Matej Marton	Komunikácia v tíme, návrh štruktúry ARX modelu
Bc. Michal Hrabovský	Automatizované hľadanie najlepších štruktúr, plánovanie tímových stretnutí

Tabuľka 5: Rozdelenie tímových úloh

Komunikácia tímu prebiehala cez skupinu na platforme *Microsoft Teams*. Na komunikáciu dohliadal **Bc. Matej Marton**, pričom tímové stretnutia plánoval **Bc. Michal Hrabovský**. Tie sa uskutočnili väčšinou medzi vedúcim a členom tímu pri dokončení jeho časti. Počas semestra sme sa okrem kontrolných stretnutí s vedúcimi stretli aj všetci dva krát – 28.4. pri dokončení simulácii ako prvej veľkej časti a následne pred tvorbou dokumentácie 15.6. Posledné stretnutie je naplánované deň pred obhajobou projektu.

Počas týchto stretnutí neprišlo k žiadnym problémom a každý si uvedomoval svoju úlohu v tíme a spoľahlivo pracoval na svojich častiach tak, aby sme projekt dokázali riadne ukončiť a odovzdať. Spätná kontrola rozhodnutí vedúceho nebola v réžii konkrétneho človeka, avšak v prípade nerealizovateľnosti navrhnutého riešenia, riešiteľ komunikoval s vedúcim / iným členom tímu, ktorý disponoval informáciami potrebnými k riešeniu problému.

Časový harmonogram bol nastavený nasledovne:

Do 1.3.2021 – zoznámiť sa s vzorovým mikrogridom

Do 21.3.2021 – vytvorenie troch mikrogridov, ktoré budú predmetom projektu

Do 11.4.2021 – zber dát zo simulácii, potrebných pre vytvorenie modelov

Do 2.5.2021 – vytvorenie NARX modelov pre každý mikrogrid

Do 15.6.2021 – vytvorenie skriptov na nájdenie najlepších parametrov pre NARX

Do 29.6.2021 – spracovanie dokumentácie

5 Záver

V prvej časti sme sa venovali vytvoreniu mikrogridov pre rôzne miesta, časy alebo situácie. Či už to bola väčšia oblasť, alebo rezidenčná zóna, či len jeden dom, ktorý disponoval obnoviteľnými zdrojmi energie, dokázali sme vytvoriť modely pre tieto prípady a vytvoriť scenáre, pri ktorých budeme schopní základné parametre elektrickej siete týchto gridov analyzovať. Venovali sme sa menovite **frekvencií, výkonu a napätiu**.

Následne sme realizovali simulácie s cieľom zozbierať variabilné dáta tak, aby sme boli schopní vytvoriť modely pre už spomenuté parametre el. siete. Každý mikrogrid bol špecifický a vyžadoval si inú periódu vzorkovania, iný čas simulácie a častokrát aj iný prístup. Ako veľký bonus môžeme hodnotiť použitie reálnych nameraných dát pre mikrogrid – veterný profil, profil variabilnej záťaže, ktoré poskytuje MATLAB vo svojom vzorovom príklade. Okrem týchto reálnych dát sme použili aj experimentálne dáta, ktoré dokážu dostať model do hraničnej situácie, či samozrejme aj náhodné dáta v rozumnom rozpätí. Tým sme získali spomínané dáta, z ktorých sme už boli schopní tvoriť NARX modely.

Modely pre prvý a druhý mikrogrid sa podarili vytvoriť výborne s tým, že funkčný bol aj uzavretý model s relatívne dobrou presnosťou (voči tréningovej presnosti). Tieto dva modely možno použiť ako náhradu reálneho mikrogridu s rovnakými parametrami jednotlivých komponentov mikrogridov. Pre čo najpresnejší model by bolo však samozrejme použiť dáta z reálnej praxe. Následne môže byť riadenie týchto gridov maximálne efektívne.

Pri treťom gride sme sa stretli s problémom nemožnosti vytvorenia presného modelu s uzavretou štruktúrou. Možné riešenie sme načrtli už aj v hodnotení tretieho gridu. Tento model je teda nepoužiteľný pre reálnu prevádzku s tým, že zrejme bude treba (minimálne) prevzorkovať, či možno použiť inú kombináciu vstupov a výstupov, pre získanie presného modelu aj pre tento prípad. V prípade možnosti použitia otvorenej štruktúry v tomto prípade je však takýto model k dispozícii a je aj dostatočne presný na tieto účely.

Pre všetky modely mikrogridov sme hľadali optimálne nastavenie pomocou skúšania viacerých kombinácií. Potom sme na základe kritérií vybrali najlepšie a tieto výsledky sme aj prezentovali v predošlých kapitolách.

6 Zdroje

- [1] NARX spätnoväzobná neurónová sieť, MATLAB
- [2] 24 hodinová simulácia V2G systému v rámci mikrogridu, MATLAB
- [3] Čo je mikrogrid? , YouTube video
- [4] Ako funguje mikrogrid, energy.gov
- [5] Ako vytvoriť mikrogrid v prostredí MATLAB/Simulink, MATLAB
- [6] Vzorové príklady a pomôcky k tvoreniu, tímový google disk
- [7] *Energies: Modelling and Simulation of Electric Vehicle Fast Charging Stations Driven by High Speed Railway Systems*, 2017, BRENNAN M., LONGO M., YAIKL W.
- [8] *Transportation Research*, vol. 2: *Electric vehicles as a new source of power for electric utilities*, no. 3, 1997, KEMPTON W., LETENDRE S.
- [9] *Journal of Power Sources: Vehicle to grid fundamentals: calculating capacity and net revenue*, vol. 144, no. 1, Jun. 2005, KEMPTON W., TOMIC J.